

ValidaFrete

Validador de cadastros de fretes com Expressões
Regulares e AFNε

Yuri Aguiar • Pedro Paulo • João Rath

Turma CC6NA • 30/09/2026

✓ 12.ABC.345/01DE-35

✓ BRA2E19

✗ ABC-1D23

✗ (23) 91234-5678

✗ 31/04/2026

✓ R\$ 1.250,00

Cadastros de fretes chegam cheios de erros


Transportadoras recebem planilhas preenchidas à mão por filiais, parceiros e clientes.

Erros de formato só aparecem quando a nota fiscal é recusada ou o motorista não é encontrado.

Desde julho de 2026 o CNPJ também pode ter letras (IN RFB 2.229/2024): validações antigas rejeitam cadastros corretos.

CNPJ	X 12ABC345/01DE-35	máscara pela metade
Placa	X ABC-1D23	Mercosul não tem hífen
Telefone	X (23) 91234-5678	DDD 23 não existe
Data	X 31/04/2026	abril tem só 30 dias
Valor	X R\$ 1.23,45	grupo de milhar com 2 dígitos

A solução: entrada, processamento e saída



Python 3

Flask

módulo re

pytest

Graphviz

Uma única fonte para a mesma linguagem


Regra central do trabalho: ER formal, slides, código, testes e AFNε devem representar a mesma linguagem.




Testes comparam AFNε × re.fullmatch em 15.000 cadeias geradas: 0 divergências.

Da Expressão Regular ao AFN ϵ : construção de Thompson


Símbolo a




União $r \mid s$ a | b




Concatenação rs ab




Fecho de Kleene r^* a^*



Opcional $r? = (r \mid \epsilon)$ $a?$



Repetição $r\{3\} = rrr$ $a\{3\}$



Setas tracejadas = movimentos ϵ . Simplificações que preservam a linguagem: a concatenação funde o final de r com o início de s , e $r?$ usa um único ϵ para pular r .

CNPJ do cliente (alfanumérico ou numérico)

ALFABETO (Σ)

$D = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$ (dígitos)
 $M = \{A, B, C, \dots, Z\}$ (26 letras maiúsculas, sem acento)
 $A = M \cup D$ (símbolos permitidos na raiz e na ordem do CNPJ)
 $\Sigma = M \cup D \cup \{'.' , '/' , '-'\}$

LINGUAGEM L

Cadeias com 14 caracteres significativos: os 12 primeiros pertencem a A (letras maiúsculas ou dígitos) e os 2 últimos, os dígitos verificadores, pertencem a D. A cadeia é escrita sem máscara (14 símbolos seguidos) ou com a máscara completa AA.AAA.AAA/AAAA-DD; máscaras parciais não pertencem a L.

ER FORMAL

$A_{\{2\}} \cdot A_{\{3\}} \cdot A_{\{3\}} / A_{\{4\}} - D_{\{2\}} \mid A_{\{12\}} D_{\{2\}}$

SINTAXE NO CÓDIGO (PYTHON)


```
re.fullmatch(r"[A-Z0-9]{2}\.[A-Z0-9]{3}\.[A-Z0-9]{3}/[A-Z0-9]{4}-[0-9]{2}|[A-Z0-9]{12}[0-9]{2}", cadeia)
```

EQUIVALÊNCIA

$[A-Z0-9]$	Classe finita: $A = M \cup D = (A \mid B \mid \dots \mid Z \mid 0 \mid 1 \mid \dots \mid 9)$
$[0-9]$	Intervalo finito: $D = (0 \mid 1 \mid \dots \mid 9)$
$\{2\}, \{3\}, \{4\}, \{12\}$	Repetição exata: $r_{\{m\}} = r \dots r$ (m cópias concatenadas)
$\cdot$	Ponto literal $\cdot$ (o escape remove o significado de "qualquer caractere")
$/$ e $-$	Símbolos literais $'/'$ e $'-'$ (fora de classes não são operadores)
$ $	União das duas formas: com máscara $ $ sem máscara

AFNε e testes

36 estados • 36 transições • 4 movimentos ε • inicial q0 • final q32 (círculo duplo)



ACEITAS (8)

✓ 12.ABC.345/01DE-35	✓ 12ABC34501DE35
✓ 11.222.333/0001-81	✓ 11222333000181
✓ A1.B2C.3D4/E5F6-07	✓ AB.CDE.FGH/IJKL-12
✓ ZZZZZZZZZZZZ99	✓ 00.000.000/0000-00

REJEITADAS (8)

✗ ε (vazia)	✗ 12.abc.345/01de-35
✗ 12.ABC.345/01DE-3A	✗ 12ABC345/01DE-35
✗ 12.ABC.345/01DE35	✗ 12ABC34501DE3
✗ 12ABC34501DE356	✗ _11222333000181

Placa do veículo (padrão antigo ou Mercosul)

ALFABETO (Σ)

$D = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$ (dígitos)
 $M = \{A, B, C, \dots, Z\}$ (26 letras maiúsculas, sem acento)
 $\Sigma = M \cup D \cup \{'-\'}$

LINGUAGEM L

Três letras maiúsculas seguidas de: (a) quatro dígitos, com ou sem um hífen entre as letras e os dígitos (padrão antigo); ou (b) dígito, letra e dois dígitos, sem hífen (padrão Mercosul).

ER FORMAL

$M\{3\} (('-' | \epsilon) D\{4\} \mid D M D\{2\})$

SINTAXE NO CÓDIGO (PYTHON)

```
re.fullmatch(r"[A-Z]{3}(-?[0-9]{4}|[0-9][A-Z][0-9]{2})", cadeia)
```

EQUIVALÊNCIA

[A-Z]

Intervalo finito: $M = (A \mid B \mid \dots \mid Z)$

[0-9]

Intervalo finito: $D = (0 \mid 1 \mid \dots \mid 9)$

{3}, {4}, {2}

Repetição exata (concatenação de cópias)

-?


Opcionalidade: $('-' \mid \epsilon)$

(... | ...)

Agrupamento da união entre padrão antigo e padrão Mercosul

AFNε e testes

16 estados • 17 transições • 5 movimentos ε • inicial q0 • final q15 (círculo duplo)



ACEITAS (8)

✓ ABC-1234	✓ ABC1234
✓ BRA2E19	✓ RI02A18
✓ QWE0Z00	✓ MNO-5678
✓ AAA-0000	✓ ZZZ9Z99

REJEITADAS (8)

✗ ε (vazia)	✗ abc1d23
✗ ABC-1D23	✗ AB-1234
✗ ABC12345	✗ ABC_1234
✗ ABC1DE3	✗ ABC-123

Telefone do motorista (fixo ou celular, com DDD válido)

ALFABETO (Σ)

$D = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$ (dígitos)
 $P = D - \{0\} = \{1, 2, \dots, 9\}$ (dígitos sem o zero)
 $F = \{2, 3, 4, 5\}$ (primeiro dígito de telefone fixo)
 $K = 1P \mid 2(1|2|4|7|8) \mid 3(1|2|3|4|5|7|8) \mid 4P \mid 5(1|3|4|5) \mid 6P \mid 7(1|3|4|5|7|9) \mid 8P \mid 9P$ (os 67 DDDs em uso)
 $\Sigma = D \cup \{'+', '(', ')', '-', '\}$

LINGUAGEM L

Números de telefone formados por: prefixo internacional +55 opcional (seguido ou não de espaço); DDD pertencente a K, entre parênteses ou sem eles; espaço opcional; número de celular (9 seguido de 8 dígitos) ou fixo (dígito de 2 a 5 seguido de 7 dígitos), com hífen opcional antes dos 4 últimos dígitos.

ER FORMAL

$('+' 55 (_ | \epsilon) | \epsilon) ('(' K ')' | K) (_ | \epsilon) (9 D\{4\} | F D\{3\}) ('-' | \epsilon) D\{4\}$

SINTAXE NO CÓDIGO (PYTHON)


```
re.fullmatch(r"(\+55 ?)?(\((1[1-9]|2[12478]|3[1-578]|4[1-9]|5[1345]|6[1-9]|7[134579]|8[1-9]|9[1-9])\)|1[1-9]|2[12478]|3[1-578]|4[1-9]|5[1345]|6[1-9]|7[134579]|8[1-9]|9[1-9]))?(9[0-9]{4}|[2-5][0-9]{3})-[0-9]{4}", cadeia)
```

EQUIVALÊNCIA

$\backslash + \quad \backslash (\quad \backslash)$	Símbolos literais '+', '(' e ')' (escapados porque são operadores)
$(\backslash + 55 ?) ?$	Opcionalidade aninhada: $('+' 55 (_ \epsilon) \epsilon)$
$[1 - 9]$	Intervalo: $P = (1 \mid 2 \mid \dots \mid 9)$
$[12478], [1 - 578], [1345], [134579]$	Classes finitas: $(1 \mid 2 \mid 4 \mid 7 \mid 8), (1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 7 \mid 8), \dots$

AFNε correspondente

84 estados • 105 transições • 48 movimentos ε • inicial q0 • final q83 (círculo duplo)



Testes e o porquê de o DDD aparecer duas vezes

Parênteses balanceados: a ER é `(' K ')` | `K` — e não `(' ? K ')?` , que aceitaria `(11 91234-5678)`.
Uma ER não tem memória para lembrar que abriu um parêntese; por isso a subexpressão `K` dos 67 DDDs é repetida, e o AFNe tem dois blocos de DDD.

ACEITAS (8)

✓ +55_(11)_91234-5678	✓ (21)_3456-7890
✓ 11912345678	✓ +5561987654321
✓ (47)98888-0000	✓ 85_3222-1100
✓ +55_31_2345-6789	✓ (99)_90000-0000

REJEITADAS (8)

✗ ε (vazia)	✗ (11_91234-5678
✗ (23)_91234-5678	✗ 11_81234-5678
✗ 11_6123-4567	✗ +55_11_91234-5678
✗ 11_91234-567	✗ +1_(11)_91234-5678

Data da coleta (DD/MM/AAAA com dia compatível com o mês)

ALFABETO (Σ)

$D = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$ (dígitos)
 $P = D - \{0\} = \{1, 2, \dots, 9\}$ (dígitos sem o zero)
 $\Sigma = D \cup \{'/'\}$

LINGUAGEM L

Datas DD/MM/AAAA com ano entre 1900 e 2099 em que: os dias 01 a 29 ocorrem em qualquer mês; o dia 30 ocorre em todos os meses exceto fevereiro; e o dia 31 ocorre apenas em janeiro, março, maio, julho, agosto, outubro e dezembro.

ER FORMAL

$((0P \mid (1|2)D) '/' (0P \mid 1(0|1|2)) \mid 30 '/' (0(1|3|4|5|6|7|8|9) \mid 1(0|1|2)) \mid 31 '/' (0(1|3|5|7|8) \mid 1(0|2))) '/' (19 \mid 20) D\{2\}$

SINTAXE NO CÓDIGO (PYTHON)


```
re.fullmatch(r"((0[1-9]|[12][0-9])/(0[1-9]|1[0-2])|30/(0[13-9]|1[0-2])|31/(0[13578]|1[02]))/(19|20)[0-9]{2}", cadeia)
```

EQUIVALÊNCIA

$0[1-9] \mid [12][0-9]$	Dias 01-29: $(0P \mid (1 2)D)$
$0[1-9] \mid 1[0-2]$	Meses 01-12: $(0P \mid 1(0 1 2))$
$[13-9]$	Classe com intervalo: $(1 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9)$, ou seja, sem o 2 (fevereiro)
$[13578], [02]$	Classes finitas dos meses com 31 dias: $(1 3 5 7 8)$ e $(0 2)$
$19 20$	União das duas possibilidades de século
$[0-9]\{2\}$	Repetição exata: $D D$

AFNε e testes

50 estados • 56 transições • 26 movimentos ε • inicial q0 • final q49 (círculo duplo)



ACEITAS (8)

✓ 01/01/2000	✓ 15/08/2025
✓ 29/02/2024	✓ 30/04/2026
✓ 31/12/1999	✓ 31/01/1900
✓ 28/02/2099	✓ 29/02/2023

REJEITADAS (8)

✗ ε (vazia)	✗ 31/04/2025
✗ 30/02/2024	✗ 00/10/2020
✗ 15/13/2020	✗ 1/1/2020
✗ 15/08/2100	✗ 15-08-2020

Valor do frete em reais (R\$)

ALFABETO (Σ)

$D = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}$ (dígitos)
 $P = D - \{0\} = \{1, 2, \dots, 9\}$ (dígitos sem o zero)
 $\Sigma = D \cup \{R, '\$', '\,', '\.', '\,'\}$

LINGUAGEM L

Cadeias iniciadas por R\$, com espaço opcional, seguidas da parte inteira — 0, ou um número sem zero à esquerda escrito inteiramente com separadores de milhar '.' em grupos de três dígitos, ou inteiramente sem separadores — e, por fim, vírgula e dois dígitos de centavos.

ER FORMAL

$R '\$' (_ | \epsilon) (0 \mid P D\{0,2\} (' D\{3\})^* \mid P D^*) ',' D\{2\}$

SINTAXE NO CÓDIGO (PYTHON)


```
re.fullmatch(r"R\$ ?(0|[1-9][0-9]{0,2}(\.[0-9]{3})*|[1-9][0-9]*),[0-9]{2}", cadeia)
```

EQUIVALÊNCIA

R\\$	Símbolos literais R e '\$' (\$ é escapado porque é âncora de fim no motor)
?	Opcionalidade do espaço: $(_ \epsilon)$
[1-9][0-9]{0,2}	Repetição limitada: $P D\{0,2\} = P (\epsilon \mid D \mid DD)$
(\.[0-9]{3})*	Fecho de Kleene: zero ou mais grupos de milhar '.' D D D
[1-9][0-9]*	Fecho de Kleene: $P D^*$ (inteiro sem separadores)
, [0-9]{2}	Vírgula literal seguida de exatamente dois dígitos

AFNε e testes

25 estados • 33 transições • 17 movimentos ε • inicial q0 • final q20 (círculo duplo)



ACEITAS (8)

✓ R\$_1.234,56	✓ R\$1500,00
✓ R\$_0,99	✓ R\$_12.345.678,90
✓ R\$_1000000,00	✓ R\$_7,00
✓ R\$_0,00	✓ R\$_999,99

REJEITADAS (8)

✗ ε (vazia)	✗ R\$_01,50
✗ R\$_1.23,45	✗ R\$_1234.567,00
✗ R\$_10,5	✗ 1.234,56
✗ R\$_1,234.56	✗ R\$_-10,00

Entradas vazias ou inválidas geram mensagens claras

Valor vazio

Entrada vazia (ϵ): a palavra vazia não pertence à linguagem desta ER.

Símbolo fora de Σ

O símbolo $_$ (posição 19) não pertence ao alfabeto Σ . Verifique se há espaços sobrando no início ou no fim.

Falha no AFN ϵ

Rejeitada na posição 5: depois de ler "31/0", o AFN ϵ não tem transição com o símbolo '4'.

Cadeia incompleta

Toda a entrada foi lida, mas o AFN ϵ terminou em estados não finais.

Arquivo

Nenhum arquivo, extensão diferente de .csv, vazio, binário, maior que 1 MB ou sem registros.

Estrutura do CSV

Colunas ausentes no cabeçalho; linha com colunas a mais ou a menos é sinalizada e o restante continua sendo processado.

Espaços extras não são removidos: " 11222333000181" é rejeitado, exatamente como nos testes — o programa reconhece a mesma linguagem da ER.

Demonstração

1

Cadeia aceita

BRA2E19 → ER-02

2

Cadeia rejeitada

(23) 91234-5678 → DDD inexistente

3

Planilha de exemplo

15 fretes: 5 válidos, 10 com erros

4

Simulação no AFNε

estados ativos a cada símbolo

Valor a validar

ER-03 · Telefone do motorista (fixo ou celular, com DDD válido)

Validar

(23) 91234-5678

Exemplos: 12.ABC.345/01DE-35 · BRA2E19 · +55 (11) 91234-5678 · 15/10/2026 · R\$ 1.250,00

Expressão	Resultado	Explicação
ER-03 · Telefone do motorista (fixo ou celular, com DDD válido)	REJEITADA	Rejeitada na posição 3: depois de ler "(2", o AFNε não tem transição com o símbolo '3'. simular no AFNε

Simular cadeia no AFNε

Cadeia

BRA-2E19

Simular

Cadeia BRA-2E19: AFNε **REJEITA** · re.fullmatch **REJEITA**

Passo	Símbolo lido	Estados ativos (após ε-fecho)
0	ε-fecho inicial	{ q0 }
1	B	{ q1 }
2	R	{ q2 }
3	A	{ q3, q4, q5, q6 }
4	-	{ q6 }
5	2	{ q8 }
6	E	∅ (nenhum estado: rejeição)

Testes e análise dos resultados

223

testes automatizados
(pytest)

80

casos das ERs
8 aceitas + 8 rejeitadas por ER

15.000

cadeias comparando
AFNε × re.fullmatch

0

falhas ou
divergências

FALSOS RESULTADOS CONHECIDOS (a ER valida o formato, não a aritmética)

ER-01 00.000.000/0000-00 é aceito: dígitos verificadores não são calculados.

ER-03 DDD existente com número inativo é aceito.

ER-04 29/02/2023 é aceito: a ER não distingue anos bissextos.

Limitações e possíveis melhorias

Limitações

- Formato $\neq$ existência: DV do CNPJ, placa registrada e telefone ativo não são consultados.
- 29/02 aceito em qualquer ano (ER-04).
- Sensível a maiúsculas e espaços, de propósito, para não alterar a linguagem.
- AFN ϵ de Thompson são grandes (84 estados na ER-03).

Melhorias

- Validação semântica após a ER: DV módulo 11 e anos bissextos.
- Converter AFN ϵ em AFD (subconjuntos) e minimizar.
- Normalização opcional com aviso ao usuário.
- Novas ERs: CEP, chave da NF-e, RNTRC; planilhas .xlsx.


Contribuições da equipe



Yuri Aguiar

Arquitetura, as 5 ERs, AFNε (Thompson), validador, CSV, interface web, testes automatizados, documentação

Thompson • ER-03 • demonstração



Pedro Paulo

Dados de exemplo, casos de teste das ER-01 e ER-02, revisão da interface

ER-01 • ER-02



João Rath

Casos de teste das ER-04 e ER-05, revisão da notação formal e do relatório

ER-04 • ER-05 • testes

Em conjunto: definição do problema, escolha das ERs e revisão dos AFNε.

Uso de IA: Claude Code (Anthropic) apoiou a estrutura do projeto, o módulo do AFNε, os scripts de documentação e a redação inicial de README, relatório e slides. Todo o conteúdo foi revisado e é explicado pela equipe.

Obrigado!

Perguntas?

Repositório: github.com/yuriaguiardev/valida-frete

Yuri Aguiar · Pedro Paulo · João Rath — CC6NA